

朱文涛

15609638530 · zwt15609638530@163.com · Scaling/生成式搜推/LLM4Rec

教育背景

北京航空航天大学 | 计算机技术 | 硕士研究生

2024.09 – 2027.06

GPA 3.81/4.0 (前 10%); 本校推免至软件国家重点实验室, 研究方向: Scaling、LLM4Rec、Agent4Rec。

北京航空航天大学 | 计算机科学与技术 | 工学学士

2020.09 – 2024.06

GPA 3.87/4.0 (前 10%); 连续三年数学竞赛省一等奖、美赛 M 奖、建模国赛省一等奖、校优秀毕业生。

实习经历

美团 | 主站搜推算法组 | **MTFM** / **MTGR**

2025.04 – 2025.10

- **MTFM 统一架构**: 针对外卖多业务独立建模痛点, 构建多场景、多序列、多目标统一精排模型; 构建统一用户画像与用户粒度聚合样本, 实现天级 UG 分离, 样本产出耗时降低 57%。将用户画像、历史/近期/实时行为、候选商家/商品构造成异构 Token 序列, 基于 HSTU 完成统一端到端建模; 设计动态混合因果掩码防止特征穿越, 引入分组层归一化对齐多语义空间。遵循 Scaling Law 将数据扩展至 100TB、参数扩展至 0.2B, 在神枪手、拼好饭场景离在线 CTR-GAUC 提升超 1.5pp, 搜索场景离线 CXR-GAUC 提升 0.51pp。
- **高效 Scaling**: 针对异构 Token 语义密度不均、算力分配失衡问题, 设计 HTA 混合注意力, 采用单层全注意力与多层目标注意力交错建模, 并结合 GQA 压缩 KV Cache, 训练吞吐提升 100% 且效果持平; 为扩充目标侧建模容量, 对 Target Token 做语义拆分与 Split-Up, 引入 per-token FFN, 并通过 SCTA 重排 TA 计算顺序, 缓解 Query Token 膨胀, 结合 Semi-Local 注意力压缩计算复杂度至线形, 支撑模型规模由 0.2B 扩容至 0.8B 且训练速度持平, 上线后首页列表收入提升 0.32%、订单量提升 0.22%; 进一步基于 UG-Sep 复用共享用户 Token 计算, RankMixer 交叉 Token 数量翻倍下, 整体复杂度基本不变, 离线 AUC 提升 0.15pp。

快手 | 直播模型组 | **OneLive**/召排一体

2025.10 – 2026.01

- **LLM 多模态表征与流式码本**: 针对 ID 表征难以感知直播实时变化的问题, 融合直播截图、主播信息、评论与 ASR, 由 GPT-4o 生成语义描述构造 SFT 数据, 蒸馏 MiniCPM-2.8B 学习统一 LUCE Emb, 以 Gate 动态融合多模态与协同信息, 聚类准确度提升 52%, 极速区间内时长提升 0.39%; 构建端到端流式 RQ-VAE, 以 Res-Kmeans 初始化码本, 采用聚类约束与对比学习均衡码本分布, 结合频控抑制 SID 抖动, 末层引入 LFQ 降低冲突, 并构建序一致性、类内一致性等评价指标, 推动 OneLive 全量召回占比提升至 80% 以上。
- **GR 高效生成与召排一体**: 为优化 GR 的生成效果与效率, 设计 Sequential MTP, 复用前序 SID 语义、浅层参数与 KV Cache, 效果持平下单机 QPS 提升 88.2%, 节省 100 台 A10; 以多模态 Emb 为教师信号, 用 <_dis>Token 进行全局对比语义蒸馏, Hit@128 提升 6.8%, 单列外流区间内时长提升 0.85%、LTV1 直播时长提升 0.96%; 以 Decoder 统一召回与粗排, 共享 QKV 主干, 并结合前缀因果注意力、粗排专属 LoRA 与梯度隔离, 召回 Hit@128 提升 3.1%、粗排 CTR-AUC 提升 0.75%、链路时延降低 54%。

字节跳动 | TikTok Search | **LLM4Rec**

2026.02 – 2026.05

- **异形卡 LLM 个性化 Query 召回**: 针对热门词、U2Q 难以刻画用户个性化意图, 融合电商长期记忆、短期行为与兴趣图谱构造用户意图 Prompt; 混合真实搜索日志与 GPT-5.5 回答结果进行 Qwen3-4B SFT, 结合 Beam Search、离/近线混合更新, HitRate@10 达到 0.748; 采用 DPO 强化业务偏好建模, 以精排高分 Query 为正样本、曝光未点击与难排序 Query 为负样本构建偏好数据, 对齐下游排序目标, 取得有效 Query 率 99.3%、全量/独占召回占比 40.2%/5.2%; PH 地区上线后 PV-CTR 提升 1.45pp、PV-CTCVR 提升 0.54pp。

阿里妈妈 | 搜索广告 | **AutoResearch**/Joint Uplift

2026.06 – 至今

- **归因驱动 AutoResearch**: 针对随机涨点、耦合改动易被误判并经长期记忆放大的问题, 构建 AutoAttribRec 多 Agent 自迭代框架; 显式定义任务条件、机制假设、代码干预与预期效应, 以模型诊断形成提案-代码-诊断三级归因验证, 并以预期/实际偏差驱动问题重构、知识检索和代码生成, 通过长短期记忆沉淀带证据及适用边界的可信认知。落地 AIGB 与 Joint Uplift 自动迭代, AIGB 模型 ACC30+4.6pt, Uplift MAPE 降低 5.7pp, 相关工作投稿 AAAI。
- **多渠道联合 Uplift**: 针对逐渠道建模难刻画渠道间替代/挤出效应、全局 PTO 放大 OOD 外推误差的问题, 以 Multi-SeqTCN 和 Sale/Treatment 分路 FiLM 建模路径依赖, 并将绝对 Uplift 转化为局部重分配边际收益; 提出 ReAlloc 快慢因果 Teacher-Student, 以去混杂 Teacher 学习局部梯度, Student 经 Replay Buffer、蒸馏及支持度/不确定性约束稳定策略。14 天、30 万商品线上 A/B 显示, PayOrder+3.5%, 平台收入 +3.2pt。

论文

UNO | 生成式序列推荐 +GRPO | AAAI Oral | 共一

AutoAttribRec | 归因 autoresearch | AAAI 在投 | 一作

MTFM | 多业务统一精排 scaling | Technical Report

Diffusion | 多源扩散模型填补 | SHM (Q1) | 一作